

Thực hành W1

Ex1: Part B

$$D_1 = [1, 0, 1, 1, 0]$$

$$D_2 = [0, 1, 1, 1, 0]$$

$$D_3 = [1, 0, 0, 1, 1]$$

Ex2: $tf(t, d) = \frac{c(t, d)}{\sum_t' c(t, d)}$

$$tf(cat, D_1) = \frac{1}{3}; \quad tf(eats, D_1) = \frac{1}{3}; \quad tf(fish, D_1) = \frac{1}{3}$$

Ex3: $idf(t) = \log \frac{N}{df(t)}$

$$idf(cat) = \log \frac{3}{2}$$

$$idf(dog) = \log \frac{3}{1} = \log 3$$

$$idf(eats) = \log \frac{3}{2}$$

$$idf(fish) = \log \frac{3}{3} = \log 1 = 0$$

$$idf(likes) = \log \frac{3}{1} = \log 3$$

- Term có idf thấp nhất là fish vì fish xuất hiện trong cả 3 ^{documents} term nên $df(fish) = 3$.

Ex4:

$$tf-idf(t, d) = tf(t, d) \cdot idf(t)$$

$$tf-idf(cat, D_1) = tf(cat, D_1) \cdot idf(cat) = \frac{1}{3} \cdot \log \frac{3}{2}$$

$$tf-idf(eats, D_1) = tf(eats, D_1) \cdot idf(eats) = \frac{1}{3} \cdot \log \frac{3}{2}$$

$$tf-idf(fish, D_1) = tf(fish, D_1) \cdot idf(fish) = \frac{1}{3} \cdot 0 = 0$$

Vì fish xuất hiện ở tất cả document, nên nó không

giúp phân biệt D_1 với các document khác nên $\text{tf-idf} = 0$

Ex5:

$$\cos(x, y) = \frac{x^T \cdot y}{\|x\|_2 \|y\|_2} = \frac{2}{\sqrt{3} \cdot \sqrt{2}} = \frac{2}{\sqrt{6}}.$$

- Đo cosine similarity để đo sự khác nhau hoặc giống nhau của 2 vectơ, không phải tỷ lệ số term giống nhau

Ex6:

- 1, Document D_1 có similarity cao nhất
- 2, Document D_3 có similarity thấp nhất.
- 3, Term có idf thấp nhất là medical và image vì xuất hiện trong $\frac{2}{3}$ documents.
- 4, Bỏ idf, chỉ dùng count vector thì ranking không thay đổi vì D_1 giống query hoàn toàn, D_2 có term chung với D_3 thì khác hoàn toàn

Part C.

- Precision 1: Nếu corpus có 80k documents, vocabulary có khoảng 90k unique terms.

- Precision 2:

+ Tf-idf matrix sẽ sparse

- Tỷ lệ zero entries có thể 90%.

- Precision 3:

Các documents đứng đầu kết quả tìm kiếm không nhất thiết là documents gần nghĩa nhất với documents đứng đầu về kết quả tìm kiếm là documents có điểm similarity cao nhất theo độ đo.