

Lab 02.

F. Btập tính toán.

B₁: Unigram.

1, $V = \{ \text{the, cat, eats, fish, likes, dog, meat} \}$.

2, $N = 4 + 4 + 4 = 12$

$$3, P(\text{the}) = \frac{C(\text{the})}{N} = \frac{3}{12} = \frac{1}{4}$$

$$P(\text{cat}) = \frac{C(\text{cat})}{N} = \frac{2}{12} = \frac{1}{6}$$

$$P(\text{fish}) = \frac{C(\text{fish})}{N} = \frac{2}{12} = \frac{1}{6}$$

$$P(\text{dog}) = \frac{C(\text{dog})}{N} = \frac{1}{12}$$

$$4, P(\text{likes}) = \frac{C(\text{likes})}{N} = \frac{1}{12}$$

$$P(\text{meat}) = \frac{C(\text{meat})}{N} = \frac{1}{12}$$

$$P(\text{eats}) = \frac{C(\text{eats})}{N} = \frac{2}{12} = \frac{1}{6}$$

$$\Rightarrow \sum_w P(w) = 1$$

B₂: Bigram.

$$P(\text{cat} | \text{the}) = \frac{C(\text{the, cat})}{C(\text{the})} = \frac{2}{3}$$

$$P(\text{dog} | \text{the}) = \frac{C(\text{the, dog})}{C(\text{the})} = \frac{1}{3}$$

$$P(\text{eats, cat}) = \frac{C(\text{cat, eats})}{C(\text{cat})} = \frac{1}{2}$$

$$P(\text{likes, cat}) = \frac{C(\text{cat, likes})}{C(\text{cat})} = \frac{1}{2}$$

giúp phân biệt D_1 với các document khác nên $tf-idf = 0$

Ex 5:

$$\cos(x, y) = \frac{x^T \cdot y}{\|x\|_2 \|y\|_2} = \frac{2}{\sqrt{3} \cdot \sqrt{2}} = \frac{2}{\sqrt{6}}$$

- Đo cosine similarity để đo sự khác nhau hoặc giống nhau của 2 vectơ, không phải tỷ lệ số term giống nhau

Ex 6:

1. Document D_1 có similarity cao nhất
2. Document D_3 có similarity thấp nhất.
3. Term có idf thấp nhất là medical và image vì xuất hiện trong $\frac{2}{3}$ documents.
4. Bỏ idf , chỉ dùng count vector thì ranking không thay đổi vì D_1 giống query hoàn toàn, D_2 có term chung còn D_3 thì khác hoàn toàn

Part C.

- Precision 1: Nếu corpus có 30k documents, vocabulary có khoảng 90k unique terms.

- Precision 2:

+ $tf-idf$ matrix sẽ sparse

- Tỷ lệ zero entries có thể 90%.

- Precision 3:

Các documents đứng đầu kết quả tìm kiếm không nhất thiết là documents gần nghĩa nhất với documents đứng đầu về kết quả tìm kiếm là documents có điểm similarity cao nhất theo độ đo.

Vì khi context cố định là the, thì từ tiếp theo là một trong các từ thuộc vocabulary. Do đó, xác suất của tất cả khả năng có thể xảy ra phải bằng 100%.

B3:

$$P(\text{the}) = \frac{1}{4}$$

$$P(\text{cat} | \text{the}) = 1$$

$$P(\text{eats} | \text{cat}) = 1$$

$$P(\text{fish} | \text{eats}) = 1$$

$$P(\text{the cat eats fish}) = \frac{1}{4} \cdot 1 \cdot 1 \cdot 1 = \frac{1}{4}$$

- Nếu thêm 1 từ xác suất của câu sẽ giảm hoặc giữ nguyên vì sẽ nhân thêm các xác suất ≤ 1 .

B4:

Dự đoán 2 câu có xác suất bằng nhau.

9. Suy luận.

$$1, \text{Count}(\text{study}, \text{AI}) = 0$$

$$\text{Count}(\text{study}) = 1$$

$$2, P(\text{AI} | \text{study}) = 0$$

3, Khi tính câu chứa bigram này xác suất sẽ bằng 0

4, Điều này không có nghĩa mô hình chắc chắn

không thể xảy ra

11. Tính smoothing

$$P_{\text{Laplace}}(\text{eats} | \text{cat}) = \frac{C(\text{cat eats}) + 1}{C(\text{cat}) + V} = \frac{1}{10+5} = \frac{1}{15}$$

$$\text{Nếu } C(\text{cat eats}) = 3 \rightarrow P_{\text{Laplace}}(\text{eats} | \text{cat}) = \frac{4}{15}$$

- Smoothing lấy 1 phần xác suất những bigram đã xuất hiện phân bổ cho những bigram chưa quan sát được nên xác suất bigram đã xuất hiện giảm và tổng xác suất bằng 1

18. Bài tập tính Perplexity.

$$P(W) = P(w_1) \cdot P(w_2 | w_1) \cdot P(w_3 | w_2)$$

$$= 0,5 \cdot 0,25 \cdot 0,5 = 0,0625$$

$$PP(W) = P(W)^{-\frac{1}{N}} = 0,0625^{-\frac{1}{3}} = \sqrt[3]{16}$$

Nếu $P(w_2 | w_1) = 0,1$:

$$P(W) = 0,5 \cdot 0,1 \cdot 0,5 = 0,025$$

$$PP(W) = 0,025^{-\frac{1}{3}} = \sqrt[3]{40}$$

- Một xác suất nhỏ làm Perplexity tăng đáng kể vì perplexity phụ thuộc nghịch đảo vào xác suất. Vậy nên xác suất càng thấp, mô hình càng bất ngờ khi gặp câu đó, perplexity càng cao.