LAB 04 - TEXT CLASSIFICATION

49.582	29.748 / 9.917 / 9.917	89,66%
Mẫu sau loại trùng	Train / Validation / Test	Test accuracy - baseline

Dữ liệu: IMDB movie reviews, phân loại cảm xúc positive/negative. ZIP chứa CSV tổng hợp 50.000 dòng; nội dung dưới đây tổng hợp kết quả chạy các notebook Colab được cung cấp.

11. Experiment 1 - Dataset inspection

Kết quả chạy

Kiểm tra	Kết quả
Số dòng trong CSV	50.000
Nhãn trước xử lý	25.000 positive (50%) và 25.000 negative (50%)
Review thiếu / rỗng	0 / 0
Review trùng	418; đã loại trước khi chia tập
Độ dài review (từ)	Trung bình 231,16; độ lệch chuẩn 171,34; nhỏ nhất 4; trung vị 173; lớn nhất 2.470
Sau loại trùng	49.582 review; 24.884 positive (50,19%) và 24.698 negative (49,81%)

Trả lời: Bộ dữ liệu có mất cân bằng lớp không?

Không đáng kể. Ban đầu hai nhãn có số lượng bằng nhau; sau khi loại review trùng, tỷ lệ vẫn gần 50/50. Đây là bài toán phân loại cảm xúc nhị phân. Accuracy có thể tham khảo cùng precision, recall, F1 và confusion matrix.

12. Data leakage - Chia dữ liệu và tiền xử lý

Kết quả chia dữ liệu

Tập	Số mẫu	Tỷ lệ	Positive / Negative
Train	29.748	60,0%	50,19% / 49,81%
Validation	9.917	20,0%	50,19% / 49,81%
Test	9.917	20,0%	50,19% / 49,81%

Các split không chồng lấp; tổng số mẫu bằng 49.582. Chia có stratify để duy trì gần như cùng tỷ lệ nhãn ở cả ba tập.

Trả lời: Vì sao fit TF-IDF trước khi chia là data leakage?

Nếu fit TF-IDF trên toàn bộ dữ liệu, vocabulary và IDF được tính cả từ validation/test. Thông tin từ tập đánh giá đã ảnh hưởng vào bước tiền xử lý, khiến đánh giá không còn khách quan. Quy trình đúng: chia tập trước; chỉ fit TF-IDF và classifier trên train; validation dùng để chọn thiết lập; test dành cho đánh giá cuối. Pipeline chỉ fit trên train.

Lưu ý: CSV trong ZIP là tập đã gộp, nên không thể khôi phục test split gốc Stanford. Test là phép chia ngẫu nhiên phân tầng mới với random_state=42.

13. Core implementation - TF-IDF + Logistic Regression

Thiết lập và kết quả chạy

Pipeline: review thô → TF-IDF (tối đa 50.000 features, unigram, min_df=2, sublinear_tf) → Logistic Regression (max_iter=1000). Vectorizer được học trên train; không bỏ stopwords để tránh xóa từ phủ định như “not”. Vocabulary có 48.487 features.

Split	Accuracy	Precision (+)	Recall (+)	F1 (+)
Validation	89,36%	88,50%	90,58%	89,52%
Test	89,66%	88,68%	91,02%	89,84%

Confusion matrix - test

Hàng là nhãn thật (negative, positive); cột là nhãn dự đoán (negative, positive).

Thực tế / Dự đoán	Negative	Positive
Negative	4.362 (TN)	578 (FP)
Positive	447 (FN)	4.530 (TP)

Trả lời / nhận xét mục 13

Mô hình đạt accuracy 89,66% và F1 89,84% trên test. Recall positive (91,02%) cao hơn precision positive (88,68%): mô hình tìm được phần lớn review positive, nhưng dự đoán nhầm 578 review negative thành positive và bỏ sót 447 review positive.

14. Experiment 2 - Baseline

Kết quả baseline TF-IDF + Logistic Regression

Thời gian là thời gian fit toàn bộ pipeline trên train trong phiên Colab.

Model	Thời gian	Vocabulary	Split	Accuracy	Precision	Recall	F1
TF-IDF + Logistic Regression	11,21 giây	48.487	Validation	89,36%	88,50%	90,58%	89,52%
TF-IDF + Logistic Regression	11,21 giây	48.487	Test	89,66%	88,68%	91,02%	89,84%

Trả lời: Baseline đạt F1 89,84% trên test. Khi báo cáo kết quả cuối, dùng hàng Test; thời gian train có thể thay đổi theo runtime và tài nguyên Colab.

15. Experiment 3 - Representation comparison

Kết quả so sánh trên cùng test set

Cả ba mô hình dùng cùng dữ liệu, split 60/20/20 và random_state=42. Model A và B cùng dùng Logistic Regression nên phù hợp để so sánh riêng hai cách biểu diễn. Model C dùng classifier khác, được thêm làm baseline tham chiếu.

Model	Representation	Classifier	Train (s)	Vocab	Accuracy	Precision	Recall	F1
A	TF-IDF	Logistic Reg.	8,01	48.484	89,67%	88,67%	91,06%	89,85%
B	Average Word2Vec	Logistic Reg.	253,19	51.395	86,18%	85,87%	86,72%	86,29%
C	TF-IDF	Linear SVM	8,06	48.484	89,26%	88,81%	89,93%	89,37%

Confusion matrix (test; thứ tự [[TN, FP], [FN, TP]])

Model	Matrix	TN	FP	FN	TP
A: TF-IDF + LR	[[4361, 579], [445, 4532]]	4.361	579	445	4.532
B: Avg Word2Vec + LR	[[4230, 710], [661, 4316]]	4.230	710	661	4.316
C: TF-IDF + SVM	[[4376, 564], [501, 4476]]	4.376	564	501	4.476

Trả lời: Tại sao hai representation tạo ra kết quả khác nhau?

Model A (TF-IDF + Logistic Regression) cho kết quả cao hơn Model B (Average Word2Vec + Logistic Regression): accuracy 89,67% so với 86,18%, F1 89,85% so với 86,29%. Model A train trong 8,01 giây, còn Model B cần 253,19 giây trong phiên này. TF-IDF giữ tín hiệu từ/cụm từ cụ thể, hữu ích khi từ vựng gắn trực tiếp với sentiment. Average Word2Vec tạo vector dày theo ngữ nghĩa nhưng phép lấy trung bình làm mất thứ tự và có thể làm yếu tín hiệu từ phủ định.

Model C đạt accuracy 89,26% và F1 89,37%, với precision cao nhất (88,81%) trong ba mô hình. Vì Model C thay cả classifier sang Linear SVM, kết quả này không cô lập riêng ảnh hưởng của representation.

Nguồn kết quả: các notebook Colab Experiment1_DataLeakage_Implemention, LAB04_IMDB_Phan_14_Experiment2 và LAB04_IMDB_Phan_15_Representation_Comparison; dữ liệu imdb.zip do người dùng cung cấp.

16. Câu hỏi quan trọng

Model nào có accuracy cao nhất?

Model A (TF-IDF + Logistic Regression) cao nhất với accuracy 89,67%. Model C (TF-IDF + Linear SVM) đạt 89,26%; Model B (Average Word2Vec + Logistic Regression) đạt 86,18%.

Tại sao hai representation tạo ra kết quả khác nhau?

TF-IDF là biểu diễn thưa, dựa trên từ/cụm từ và giữ tín hiệu từ vựng trực tiếp. Những từ như “excellent”, “boring” hoặc “not good” có thể là đặc trưng phân biệt sentiment. Average Word2Vec là biểu diễn dày theo ngữ nghĩa; lấy trung bình các vector làm mất thứ tự từ và có thể làm mờ tác động của từ phủ định hoặc một từ đặc biệt quan trọng.

Trong thí nghiệm dùng cùng Logistic Regression và cùng split, TF-IDF đạt F1 89,85%, cao hơn Average Word2Vec 86,29%; kết quả này cho thấy representation TF-IDF phù hợp hơn với baseline và dữ liệu IMDB trong lần chạy này. Model C đổi sang Linear SVM, nên không thể quy chênh lệch giữa C với A chỉ cho representation.

17. Experiment 4 - Word order

Kết quả chạy trên IMDB

Word2Vec được huấn luyện trên 29.748 review train; vocabulary có 51.395 từ. Thời gian huấn luyện trong phiên Colab là 191,27 giây. Tất cả token trong hai câu ví dụ đều có trong vocabulary.

Phép đo	**Kết quả**
S1	this movie is good
S2	this movie is not good
Tokens S1 / S2	['this', 'movie', 'is', 'good'] / ['this', 'movie', 'is', 'not', 'good']
Cosine similarity: S1 và S2	0,9795
Cosine similarity: S2 và “this movie is good not”	1,0000
L2 distance: S1 và S2	0,4143
Từ “not” có vector đã học?	Có; norm vector = 2,6705

Trả lời câu hỏi: Representation này có hiểu được vai trò của “not” không?

“not” có trong vocabulary và vector của nó thực sự được cộng vào average embedding của S2; từ này không bị loại bỏ. Tuy nhiên, phép lấy trung bình không biểu diễn “not” như một phép phủ định làm đảo nghĩa “good”. Do S1 và S2 có nhiều từ chung, hai vector vẫn rất gần nhau (cosine 0,9795), dù sắc thái cảm xúc trái ngược.

Phép thử đảo thứ tự cho thấy S2 và “this movie is good not” có cùng các token, nên average embedding của hai câu giống hệt nhau (cosine 1,0000). Đây là bằng chứng trực tiếp rằng average Word2Vec không giữ word order.

Kết luận: Average Word2Vec ghi nhận vector của các từ nhưng trung bình hóa làm mất vị trí và quan hệ phủ định; vì vậy có thể không phân biệt tốt các câu mà một từ như “not” làm đổi polarity.

Nguồn: output notebook Colab LAB04_IMDB_Phan_17_Word_Order.ipynb.

18. Experiment 5 - n-gram features

Kết quả chạy trên test set

Cả hai mô hình dùng cùng split 60/20/20, TF-IDF và Logistic Regression. Model A dùng unigram; Model B dùng unigram + bigram.

Model	Features	Vocabulary	Train time	Accuracy	Precision	Recall	F1
A	Unigram	48.484	9,41 s	89,67%	88,67%	91,06%	89,85%
B	Unigram + Bigram	493.564	28,84 s	90,02%	88,78%	91,70%	90,22%

Thay đổi khi thêm bigram

Đại lượng	Kết quả
Features mới	445.080; vocabulary tăng khoảng 10,2 lần
Training time	Tăng từ 9,41 lên 28,84 giây (khoảng 3,1 lần)
F1	Tăng 0,0037, tương đương +0,37 điểm phần trăm
Accuracy / Precision / Recall	Lần lượt tăng +0,35 / +0,11 / +0,64 điểm phần trăm
Feature check	“not good” và “very good” có trong unigram + bigram, không có trong unigram-only

Confusion matrix - test

Hàng là nhãn thật (negative, positive); cột là nhãn dự đoán (negative, positive).

Model	TN	FP	FN	TP	Matrix [[TN, FP], [FN, TP]]
Unigram	4.361	579	445	4.532	[[4361, 579], [445, 4532]]
Unigram + Bigram	4.363	577	413	4.564	[[4363, 577], [413, 4564]]

Trả lời câu hỏi mục 18

Bigram giúp mô hình nhận diện cụm từ có ý nghĩa như “not good” và “very good”, thay vì chỉ xét từng từ rời rạc. Trong lần chạy này, unigram + bigram cải thiện F1 lên 90,22% và recall lên 91,70%; confusion matrix cũng cho thấy false negative giảm từ 445 xuống 413.

Đổi lại, feature space tăng thêm 445.080 features và thời gian huấn luyện tăng khoảng 3,1 lần. Với dữ liệu này, bigram mang lại cải thiện nhỏ về F1 (+0,37 điểm phần trăm) so với chi phí tăng đáng kể. Kết luận: bigram có ích trong lần thử này nhưng cần cân nhắc tài nguyên; thêm bigram không đảm bảo lúc nào cũng cải thiện hiệu năng.

Nguồn: output notebook Colab LAB04_IMDB_Phan_18_Ngram_Features.ipynb.

23. Application - Option B: Topic Classification

Dataset: AG News, 5,000 samples per class (20,000 total), stratified Train/Validation/Test = 12,000/4,000/4,000. Model: TF-IDF unigram + bigram and Logistic Regression; vocabulary size: 64,053 features.

Test results

Accuracy	Macro Precision	Macro Recall	Macro F1
0.8870	0.8867	0.8870	0.8865

Validation: accuracy 0.8980, macro-F1 0.8977.

Classification report (test)

Ch■ ■■	Precision	Recall	F1	Support
World/Politics	0.9062	0.8700	0.8878	1,000
Sports	0.9213	0.9720	0.9460	1,000
Business	0.8643	0.8410	0.8525	1,000
Technology	0.8547	0.8650	0.8598	1,000

Confusion matrix (rows = actual, columns = predicted)

Actual / Predicted	World/Politics	Sports	Business	Technology
World/Politics	870	43	54	33
Sports	10	972	8	10
Business	39	16	841	104
Technology	41	24	70	865

Interpretation

The model correctly classifies 88.70% of news items. Sports performs best (F1 = 0.9460). The largest confusion is Business predicted as Technology (104 items), likely because the topics share vocabulary about companies and technology. Macro-F1 is close to accuracy, indicating balanced performance across the four classes.

All four example predictions are correct: championship match -> Sports; central bank and interest rates -> Business; AI processor -> Technology; election reforms -> World/Politics.