lab08

1. Bài 12

Tokenizer: bert-base-uncased

Output keys: input_ids, token_type_ids, attention_mask

input_ids ánh xạ mỗi token thành ID trong vocabulary. attention_mask dùng 1 cho token hợp lệ và 0 cho vị trí padding.

Câu 1: The cats are playing. | Số từ (tách theo khoảng trắng): 4

Subword pieces:

```
['the', 'cats', 'are', 'playing', '.']
```

Tokens (gồm special/padding tokens):

```
['[CLS]', 'the', 'cats', 'are', 'playing', '.', '[SEP]', '[PAD]', '[PAD]', '[PAD]',
    '[PAD]', '[PAD]', '[PAD]']
```

input_ids:

```
[101, 1996, 8870, 2024, 2652, 1012, 102, 0, 0, 0, 0, 0, 0]
```

attention_mask:

```
[1, 1, 1, 1, 1, 1, 1, 0, 0, 0, 0, 0, 0]
```

special token mask (1 = token đặc biệt):

```
[1, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1]
```

Câu 2: The cats are playing in the garden with their friends. | Số từ (tách theo khoảng trắng): 10

Subword pieces:

```
['the', 'cats', 'are', 'playing', 'in', 'the', 'garden', 'with', 'their', 'friends',
    '.']
```

Tokens (gồm special/padding tokens):

```
['[CLS]', 'the', 'cats', 'are', 'playing', 'in', 'the', 'garden', 'with', 'their',
    'friends', '.', '[SEP]']
```

input_ids:

```
[101, 1996, 8870, 2024, 2652, 1999, 1996, 3871, 2007, 2037, 2814, 1012, 102]
```

attention_mask:

```
[1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1]
```

special token mask (1 = token đặc biệt):

```
[1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1]
```

Special tokens

[CLS], [SEP], [PAD], [UNK], [MASK]

Kích thước batch input_ids: (2, 13)

2. Bài 13 — Classification Head

Text: The movie was excellent.

Input keys: input_ids, token_type_ids, attention_mask

[CLS] representation shape: (1, 768)

Logits: [-0.185731, -0.315061]

Softmax probabilities: [0.532287, 0.467713]

Demo prediction: negative. Classification head chưa huấn luyện nên dự đoán này chỉ minh họa pipeline, chưa phải kết quả sentiment có ý nghĩa.

3. Bài 14 - Pretrained vs From Scratch

Kết quả trên test (256 mẫu):

Transformer from scratch: Accuracy = 0.5430; F1 = 0.0000; thời gian train = 4.45 giây; 109,483,778 tham số.

Pretrained Transformer: Accuracy = 0.6914; F1 = 0.5907; thời gian fine-tuning = 3.61 giây; 109,483,778 tham số.

Validation: scratch Accuracy = 0.4609, F1 = 0.0000; pretrained Accuracy = 0.6719, F1 = 0.6038.

Câu 1: Scratch bắt đầu từ trọng số ngẫu nhiên nên phải học biểu diễn và phân loại đồng thời. Pretrained bắt đầu từ biểu diễn ngữ cảnh đã học trên văn bản lớn rồi điều chỉnh theo IMDb. Kết quả phù hợp với khác biệt này: trên test, pretrained cao hơn 0.1484 Accuracy và 0.5907 F1; scratch có F1 = 0.0000.

Câu 2: Với lượng dữ liệu gán nhãn downstream nhỏ, pretrained thường cần ít ví dụ hơn vì đã có biểu diễn ban đầu hữu ích. Trong thí nghiệm này chỉ dùng 256 mẫu train nhưng pretrained vẫn đạt Accuracy = 0.6914, cao hơn scratch = 0.5430. Đây là bằng chứng trên tập con nhỏ, chưa đủ để khái quát cho mọi dữ liệu.

Câu 3: Hai mô hình có cùng kiến trúc và 109,483,778 tham số, nên chi phí tính toán cho mỗi bước train cùng bậc. Thời gian đo được là 4.45 giây từ scratch và 3.61 giây fine-tuning trên T4. Thời gian này không tính chi phí pretraining BERT đã thực hiện trước đó; scratch cũng chưa đạt chất lượng tương đương sau một epoch.

Câu 4: Notebook không ghi lại dự đoán trước thí nghiệm, nên không thể đối chiếu với một dự đoán cá nhân đã lưu. Nếu dùng kỳ vọng pretrained sẽ tốt hơn khi downstream data ít, kết quả quan sát phù hợp: pretrained đạt Accuracy/F1 cao hơn scratch. Kết luận chỉ áp dụng cho split con 256/128/256 và một epoch; cần nhiều dữ liệu, epoch và lần chạy hơn để đánh giá chắc chắn.

4. Bài 15 - Feature Extraction vs Fine-Tuning

Kết quả trên test (256 mẫu): Frozen encoder: Accuracy = 0.5586; F1 = 0.1102; thời gian train = 1.84 giây; 1,538 tham số được train. Fine-tuning: Accuracy = 0.6914; F1 = 0.5907; thời gian train = 3.39 giây; 109,483,778 tham số được train.

Validation: Frozen Accuracy = 0.4922, F1 = 0.1558; fine-tuning Accuracy = 0.6719, F1 = 0.6038.

Câu 1: Frozen encoder vẫn phân loại được vì BERT pretrained tạo ra biểu diễn ngữ cảnh hữu ích cho câu; classification head mới được huấn luyện để ánh xạ biểu diễn đó sang nhãn sentiment. Kết quả có Accuracy 0.5586 nhưng F1 chỉ 0.1102 trên test, cho thấy biểu diễn cố định và head nhỏ còn hạn chế với thiết lập ít dữ liệu/ít epoch này.

Câu 2: Fine-tuning cho phép điều chỉnh các biểu diễn bên trong BERT theo ngôn ngữ đánh giá phim IMDb, thay vì chỉ học lớp phân loại cuối. Trong thí nghiệm, fine-tuning đạt Accuracy 0.6914 và F1 0.5907, cao hơn frozen (0.5586 và 0.1102); validation cũng cao hơn. Đổi lại, số tham số cập nhật tăng từ 1,538 lên 109,483,778 và thời gian train tăng từ 1.84 lên 3.39 giây. Đây là kết quả trên tập con 256 mẫu train, một epoch và một seed; learning rate cũng được chọn theo chế độ, nên cần nhiều lần chạy/dữ liệu hơn để kết luận tổng quát.

5. Bài 16 - Amount of Training Data

Kết quả trên test:

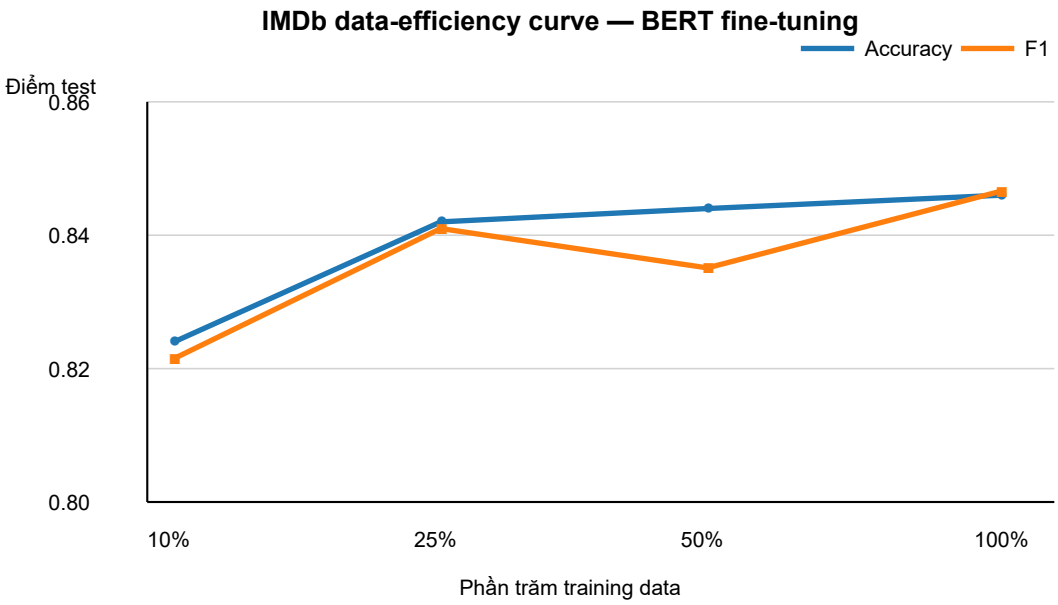
10% (2,500): Accuracy = 0.8240; F1 = 0.8215; train = 30.0 giây.

25% (6,250): Accuracy = 0.8420; F1 = 0.8410; train = 78.6 giây.

50% (12,500): Accuracy = 0.8440; F1 = 0.8351; train = 159.4 giây.

100% (25,000): Accuracy = 0.8460; F1 = 0.8466; train = 318.2 giây.

Câu hỏi: Pretraining có giúp model sử dụng dữ liệu downstream hiệu quả hơn không? Trên toàn đường cong, mô hình pretrained đã đạt Accuracy/F1 = 0.8240/0.8215 khi dùng 10% dữ liệu (2,500 mẫu); đến 100%, hai điểm tăng lên 0.8460/0.8466. Accuracy tăng đều, còn F1 giảm nhẹ từ 25% xuống 50% rồi tăng ở 100%, vì vậy cần xét toàn bộ xu hướng thay vì một điểm riêng. Kết quả gợi ý biểu diễn pretrained hữu ích ngay cả khi downstream data bị giới hạn, nhưng mức cải thiện thêm sau 25% khá nhỏ trong thí nghiệm này. Bài 16 chỉ chạy BERT pretrained; để chứng minh trực tiếp pretrained hiệu quả dữ liệu hơn model from-scratch, cần so sánh hai loại model ở cùng bốn mức dữ liệu, split và thiết lập.



6. Bài 17 - Maximum Sequence Length

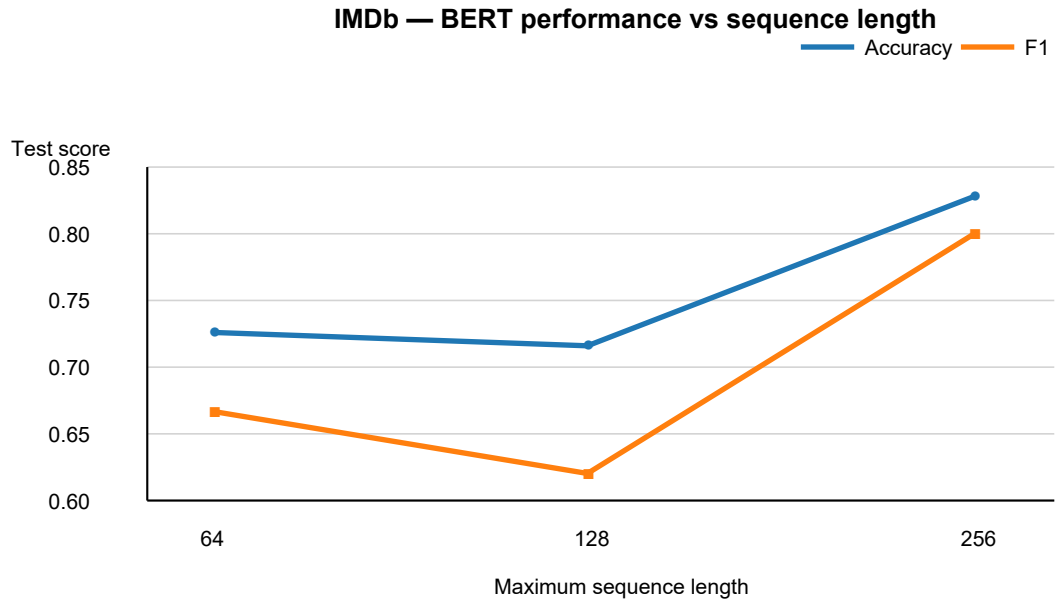
Kết quả trên test:

max_length 64: Accuracy = 0.7260; F1 = 0.6667; train = 16.0 giây; GPU peak = 2.06 GB; CPU RSS peak = 1.66 GB.

max_length 128: Accuracy = 0.7160; F1 = 0.6203; train = 23.3 giây; GPU peak = 2.09 GB; CPU RSS peak = 1.72 GB.

max_length 256: Accuracy = 0.8280; F1 = 0.8000; train = 44.9 giây; GPU peak = 2.50 GB; CPU RSS peak = 1.73 GB.

Câu hỏi: Tăng sequence length luôn làm model tốt hơn không? Không. Trong phép thử này, tăng từ 64 lên 128 làm Accuracy giảm 0.0100 và F1 giảm 0.0464; tăng tiếp lên 256 mới cải thiện rõ, đạt Accuracy 0.8280 và F1 0.8000. Đổi lại, thời gian train tăng từ 16.0 lên 44.9 giây và GPU memory peak tăng từ 2.06 lên 2.50 GB. Độ dài lớn có thể giữ lại ngữ cảnh ở các review dài, nhưng chỉ hữu ích nếu phần ngữ cảnh thêm thực sự hỗ trợ dự đoán. Self-attention có thành phần chi phí tăng theo O(T^2), nên nên chọn độ dài theo đường cong chất lượng, thời gian và bộ nhớ. Kết luận này giới hạn ở 1,000 mẫu train, một epoch, một seed và 500 mẫu test; cần lặp nhiều seed/tập lớn hơn để khái quát.



7. Bài 18 - Domain Shift

Output:

```
Device: cpu | GPU: CPU
step 10/63 | loss=0.7274
step 20/63 | loss=0.6219
step 30/63 | loss=0.5937
step 40/63 | loss=0.6401
step 50/63 | loss=0.4845
step 60/63 | loss=0.3430
step 63/63 | loss=0.5097

=== Domain shift results (balanced 500-example test sets) ===
Train: IMDb 1,000 balanced reviews | max_length=128 | epochs=1 | seed=42
IMDb in-domain:  Accuracy=0.8280 Precision=0.8254 Recall=0.8320 F1=0.8287
IMDb confusion matrix [true 0/1 × pred 0/1]: [[206, 44], [42, 208]]
Yelp out-domain:  Accuracy=0.8560 Precision=0.8069 Recall=0.9360 F1=0.8667
Yelp confusion matrix [true 0/1 × pred 0/1]: [[194, 56], [16, 234]]
Validation IMDb:  Accuracy=0.8320 F1=0.8346
Training time: 875.3s

Kết luận dựa trên số liệu: so sánh IMDb in-domain với Yelp out-domain để xem khả năng
    giảm chất lượng khi chuyển miền.
```

Câu hỏi: Model pretrained có nghĩa là đã hiểu mọi domain không? Không thể kết luận như vậy. Trong thí nghiệm này, sau khi huấn luyện trên IMDb, model đạt Accuracy/F1 = 0.8280/0.8287 trên IMDb và 0.8560/0.8667 trên Yelp. Kết quả cho thấy chuyển miền sang tập Yelp này vẫn tốt, nhưng chỉ thử hai bộ review và 500 mẫu cân bằng mỗi miền; chênh lệch dữ liệu giữa hai bộ cũng có thể ảnh hưởng điểm số. Vì vậy, pretrained không đảm bảo model hiểu mọi domain; cần kiểm tra riêng trên từng miền mục tiêu.

8. Bài 19 - Sentiment Classification

Output:

```
Device: cuda | GPU: Tesla T4
step 10/63 | loss=0.7058
step 20/63 | loss=0.6199
step 30/63 | loss=0.5563
step 40/63 | loss=0.6864
step 50/63 | loss=0.4634
step 60/63 | loss=0.3021
step 63/63 | loss=0.5631

=== IMDb sentiment classification (test) ===
Accuracy: 0.8260
Precision (positive): 0.9095
Recall (positive): 0.7240
F1 (positive): 0.8062
Confusion matrix [true 0/1 x pred 0/1]:
[[232  18]
 [ 69 181]]
Training time: 23.8s
```

Trả lời: Không nên đánh giá model chỉ bằng Accuracy = 0.8260. Precision = 0.9095 cho thấy dự đoán positive khá chính xác, nhưng Recall = 0.7240 thấp hơn: model nhận ra 181/250 review positive và bỏ sót 69 review positive. F1 = 0.8062 cân bằng Precision và Recall; confusion matrix cũng cho thấy 18 false positive và 69 false negative. Vì vậy cần đọc đủ các metric và ma trận nhầm lẫn để thấy loại lỗi của model.

9. Bài 21 - Confidence Analysis

Output:

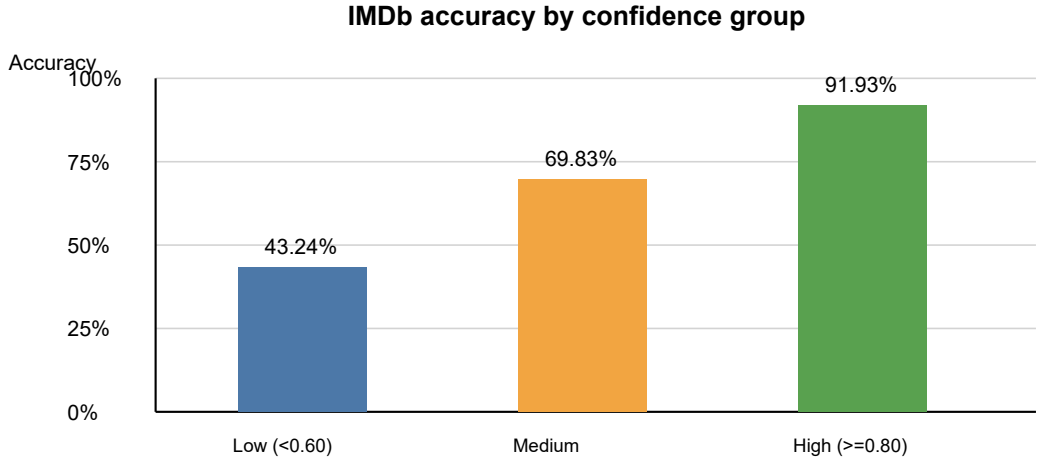
```
Device: cpu | GPU: CPU
step 10/63 | loss=0.7274
step 20/63 | loss=0.6219
step 30/63 | loss=0.5937
step 40/63 | loss=0.6401
step 50/63 | loss=0.4845
step 60/63 | loss=0.3430
step 63/63 | loss=0.5097

=== Accuracy by confidence group ===
  confidence_group  samples accuracy  errors mean_confidence
       Low (<0.60)       37   43.24%      21          0.5586
Medium (0.60–0.80)      116   69.83%      35          0.7249
     High (>=0.80)      347   91.93%      28          0.8561
```

```
Overall accuracy: 0.8320
Incorrect predictions with confidence >= 0.80: 28
Training time: 934.1s

=== Top 5 confident wrong predictions ===
index=378 | true=positive | pred=negative | confidence=0.8931
index=341 | true=positive | pred=negative | confidence=0.8917
index=445 | true=positive | pred=negative | confidence=0.8794
index=160 | true=positive | pred=negative | confidence=0.8639
index=44 | true=positive | pred=negative | confidence=0.8614
```

Ví dụ văn bản in ra cho các dự đoán sai tự tin cao: index 378 bắt đầu “The dead spots and picture-postcard superficiality of ‘Out of Africa’…”; index 341: “I rank OPERA as one of the better Argento films…”; index 445: “You gotta love the spaghetti western universe…”; index 160: “The problem with so many people watching this movie is the mindset…”; index 44: “Sadly, this movie is relegated to ‘curio’ status it seems…”. Cả năm ví dụ đều là positive nhưng bị dự đoán negative.



Trả lời: Confidence cao không đảm bảo dự đoán đúng. Accuracy tăng theo ba nhóm confidence trong lần chạy này (43.24%, 69.83%, 91.93%), nhưng trong nhóm High vẫn có 28 lỗi trên 347 mẫu, tương đương 8.07%; tổng độ chính xác là 83.20%. Confidence là xác suất lớn nhất sau softmax, không tự nó chứng minh rằng xác suất đã được hiệu chỉnh tốt. Các ví dụ sai đều là review positive bị gán nhãn negative với confidence 0.8614–0.8931, minh họa rằng mô hình có thể sai nhưng rất tự tin.

10. Bài 22 - Ablation / Analysis

Output:

```
Device: cuda
Train: 1000 balanced reviews | Test: 500 balanced reviews

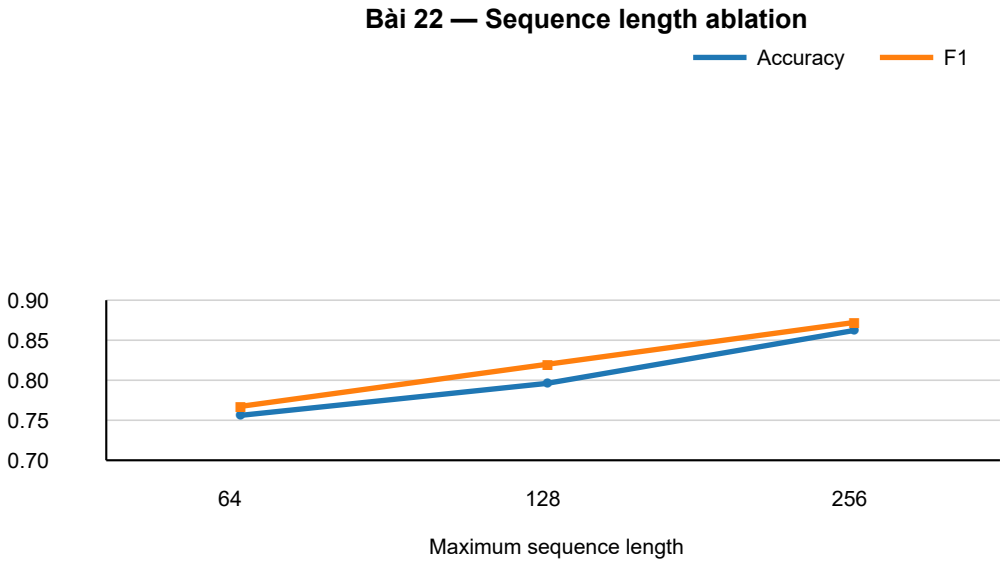
=== max_length=64 ===
epoch 1/1 | mean loss=0.6556
Accuracy=0.7560 | Precision=0.7336 | Recall=0.8040 | F1=0.7672
Confusion matrix [true 0/1 x pred 0/1]: [[177, 73], [49, 201]]
Training + evaluation time: 32.4s

=== max_length=128 ===
epoch 1/1 | mean loss=0.5930
Accuracy=0.7960 | Precision=0.7342 | Recall=0.9280 | F1=0.8198
Confusion matrix [true 0/1 x pred 0/1]: [[166, 84], [18, 232]]
Training + evaluation time: 25.2s

=== max_length=256 ===
epoch 1/1 | mean loss=0.5233
Accuracy=0.8620 | Precision=0.8131 | Recall=0.9400 | F1=0.8720
Confusion matrix [true 0/1 x pred 0/1]: [[196, 54], [15, 235]]
Training + evaluation time: 50.7s

=== Controlled comparison ===
 max_length accuracy precision recall     f1 seconds
         64   0.7560    0.7336 0.8040 0.7672    32.4
        128   0.7960    0.7342 0.9280 0.8198    25.2
        256   0.8620    0.8131 0.9400 0.8720    50.7
Trả lời câu hỏi phân tích: tăng sequence length không nhất thiết luôn làm model tốt hơn.
```

```
Trong các cấu hình đã thử, max_length=256 có F1 cao nhất (0.8720) và
Accuracy=0.8620. Hãy đối chiếu thêm thời gian chạy và các confusion matrix ở trên;
kết luận chỉ áp dụng cho split, seed và một epoch của thí nghiệm này.
```



Phân tích: Trong lần chạy này, Accuracy và F1 tăng ở cả ba độ dài; max_length=256 đạt kết quả tốt nhất (Accuracy 0.8620, F1 0.8720). Thời gian đo cho cấu hình 256 là 50.7 giây, cao hơn 32.4 giây ở cấu hình 64; lần chạy 128 mất 25.2 giây. Confusion matrix cho thấy false negative giảm từ 49 (64) xuống 18 (128) và 15 (256), còn false positive tăng từ 73 lên 84 rồi giảm còn 54. Kết quả gợi ý phần ngữ cảnh dài hơn hữu ích với mẫu thử này, nhưng chưa chứng minh độ dài lớn luôn tốt hơn: thí nghiệm chỉ dùng một split cân bằng 1,000/500 mẫu, một seed và một epoch.